

Assistant RAG en production avec évaluation continue de la qualité

Exercice C2 — Master 1 Intelligence Artificielle et Science des Données

Code source : <https://github.com/N4212/rag-assistant-rh>

1. Contexte métier et problématique

Le département des ressources humaines d'une entreprise cherche à mettre à disposition de ses collaborateurs un assistant capable de répondre à leurs questions à partir des procédures internes existantes. Le bénéfice est double : le service RH cesse de traiter manuellement des demandes répétitives, et le collaborateur obtient une réponse immédiate, à toute heure, sans avoir à solliciter un interlocuteur pour une question qu'il juge parfois trop mineure pour être posée.

L'approche retenue est le RAG (Retrieval-Augmented Generation). Comparée à une recherche par mots-clés, elle permet de retrouver les passages dont le sens correspond à la question, même lorsque la formulation diffère de celle du document : « comment poser des congés » et « procédure de demande de vacances » n'ont presque aucun terme en commun, mais expriment la même intention. Comparée à l'usage d'un grand modèle de langage seul, sans corpus, elle évite que le système invente des procédures plausibles mais étrangères à l'entreprise — ce qui reviendrait à diffuser de fausses informations auprès des salariés.

Une fois l'outil livré et calibré, rien ne garantit qu'il conservera le niveau de qualité mesuré le premier jour. Les procédures RH évoluent : une convention est révisée, un barème change, une note interne est reformulée. Le fournisseur du modèle de langage peut lui aussi modifier son offre, retirer une version ou durcir ses quotas. Ces deux risques n'ont toutefois pas la même nature. Un changement de modèle provoque une panne visible, que l'on détecte immédiatement. Une procédure modifiée, elle, ne casse rien : l'assistant continue de répondre avec la même assurance et cite une source qui existe réellement, mais dont le contenu est désormais périmé. Personne ne s'en aperçoit tant qu'un collaborateur n'a pas agi sur une réponse obsolète.

C'est précisément ce risque silencieux qui motive ce projet. Vérifier manuellement la qualité des réponses chaque jour n'est pas envisageable : il faut un dispositif qui mesure cette qualité de façon automatique, en conserve l'historique, et signale de lui-même toute dégradation.

2. Architecture du système

Le système se décompose en trois ensembles qui n'ont ni la même périodicité ni la même finalité : une phase d'indexation exécutée une seule fois, une phase d'interrogation déclenchée à chaque question, et une phase de mesure rejouée périodiquement.

2.1 Indexation

Les dix documents du corpus RH sont découpés en fragments de 500 caractères, avec un chevauchement de 100 caractères entre fragments successifs. Ce recouvrement évite qu'une information située à la frontière de deux fragments ne se retrouve tronquée dans les deux.

Chaque fragment est converti en vecteur de 384 dimensions par le modèle `paraphrase-multilingual-MiniLM-L12-v2` exécuté localement. Ces vecteurs, les textes correspondants et leurs métadonnées — document




Figure 1: Architecture du système

d'origine, position — sont stockés dans une base vectorielle Chroma persistée sur disque. Chaque fragment est préfixé du nom de son document source avant vectorisation : un fragment isolé peut ne contenir qu'une portion de tableau, sans son titre de section, et le préfixe lui restitue un minimum de contexte.

2.2 Interrogation

La question est vectorisée par le même modèle que celui utilisé à l'indexation — condition nécessaire, deux modèles distincts produisant des espaces vectoriels incomparables. Chroma retourne les cinq fragments les plus proches.

Ces fragments sont assemblés en un contexte transmis à l'API Gemini, accompagné de la question et d'une consigne système. Cette consigne impose deux comportements : répondre exclusivement à partir des extraits fournis, et déclarer explicitement ne pas disposer de l'information lorsqu'elle ne s'y trouve pas. La réponse mentionne le document d'origine, ce qui permet au collaborateur de remonter à la source.

2.3 Mesure et surveillance

Un jeu de vingt questions de référence, dont les réponses attendues sont connues, constitue l'étalon de qualité. Prefect déclenche son exécution chaque nuit et conserve l'historique des exécutions — statut, durée, journaux. MLflow enregistre les paramètres de la configuration testée et les métriques obtenues, ce qui rend les exécutions comparables dans le temps. Lorsque le taux de réponses correctes passe sous le seuil de 90 %, le flux émet une requête HTTP vers un webhook n8n, qui se charge de la notification. Chaque exécution régénère enfin le rapport de suivi, document Markdown accompagné de deux graphiques.

Deux outils d'orchestration coexistent donc, avec des rôles distincts. Prefect orchestre le code Python interne : il exécute, réessaie, journalise. n8n orchestre la réaction vers l'extérieur. Ce découplage a une conséquence pratique : modifier le destinataire d'une alerte ou ajouter un canal ne demande aucune intervention dans le code Python, mais seulement une reconfiguration du dernier nœud du workflow.

3. Choix techniques

Plusieurs arbitrages structurent le système. Les trois premiers sont résumés ci-dessous ; les trois suivants font l'objet d'un développement, soit qu'ils conditionnent la faisabilité de l'évaluation, soit qu'ils aient posé une difficulté particulière.

Choix	Alternative écartée	Raison
Modèle d'embedding multilingue	Modèle anglophone	Corpus et questions en français ; exécution locale, sans quota ni sortie de données à l'indexation
Chroma	Qdrant, Weaviate, Milvus	69 fragments seulement : aucun gain d'une infrastructure serveur ; Chroma s'intègre en bibliothèque

Choix	Alternative écartée	Raison
Fragments de 500, <code>top_k</code> 5	Autres valeurs testées	Issus du plan d'expérience de la section 5, non d'un choix a priori

Le modèle retenu est **paraphrase-multilingual-MiniLM-L12-v2**, entraîné sur plusieurs langues dont le français. Les modèles les plus répandus de cette famille, comme **all-MiniLM-L6-v2**, sont entraînés exclusivement sur de l'anglais et dégradent fortement la recherche sur un corpus français.

Deux propriétés de Chroma ont pesé au-delà du stockage : il conserve le texte original aux côtés du vecteur — le vecteur sert à retrouver, le texte est transmis au modèle — et accepte des métadonnées libres, ce qui permet de citer les sources et rend possible la mesure du rappel présentée plus loin.

3.1 Le corpus

Trois corpus réels avaient été envisagés : une documentation technique open source, le règlement des études de l'établissement, ou des rapports économiques publics. Le choix s'est porté sur un corpus fictif de dix procédures RH.

Ce choix tient à la nature de l'exercice. Le cœur du projet n'est pas l'ingestion de documents mais la mesure de la qualité des réponses dans la durée. Un corpus réel aurait imposé un travail de conversion et de nettoyage sans rien apporter à la démonstration du dispositif de surveillance.

Le contrôle total du contenu a surtout rendu l'évaluation possible. Chaque document contient des faits précis et vérifiables : un barème kilométrique de 0,45 euro, un délai de carence de trois jours, une longueur minimale de quatorze caractères pour un mot de passe. Une réponse portant sur ces informations est correcte ou fausse, sans zone intermédiaire. Un corpus aux formulations vagues n'aurait autorisé aucune métrique binaire.

Le même contrôle a permis d'y placer des difficultés délibérées. Le document sur l'entretien annuel décrit deux dispositifs voisins que l'on confond facilement. La question du télétravail d'un nouvel arrivant exige de croiser deux documents distincts. Le congé sabbatique et le compte épargne-temps, enfin, ne figurent nulle part : ils servent à vérifier que l'assistant reconnaît son ignorance au lieu d'inventer une procédure plausible.

La contrepartie est assumée : un corpus réel serait plus bruité — formulations ambiguës, contradictions, structures hétérogènes — et les taux mesurés ici sont vraisemblablement supérieurs à ceux qu'obtiendrait le même système sur des procédures authentiques.

3.2 Le modèle de langage

Le choix de Gemini répond d'abord à une contrainte budgétaire. L'API Claude fonctionne au crédit prépayé et n'entraîne pas dans le cadre de ce projet étudiant ; l'exécution d'un modèle en local supposait une machine suffisamment dotée, ce qui n'était pas le cas de l'environnement de développement utilisé.

Ce choix s'est révélé plus instable que prévu. Le modèle initialement retenu, **gemini-2.0-flash**, avait été retiré et redirigeait vers **gemini-3.6-flash**. Ce dernier fonctionnait, mais avec un quota gratuit de vingt requêtes par jour, alors qu'une seule évaluation complète en consomme quarante. Un

troisième modèle, `gemini-2.5-flash-lite`, n'était plus ouvert aux nouveaux comptes. Le système tourne finalement sur `gemini-3.5-flash-lite`, limité à quinze requêtes par minute.

Cette succession a directement façonné le code : la temporisation de huit secondes entre deux questions et le mécanisme de réessai avec attente croissante existent uniquement pour absorber ces quotas. Elle illustre un risque structurel du recours à une API externe — le fournisseur peut retirer un modèle ou en restreindre l'accès sans préavis.

En contexte professionnel, un modèle hébergé en interne serait préférable pour un assistant RH : les documents ne sortiraient pas du réseau de l'entreprise, aucun quota ne contraindrait le volume de requêtes, et la version du modèle resterait sous contrôle, ce qui garantit la reproductibilité des mesures. Cette option a néanmoins un coût — serveur, administration — et les modèles auto-hébergés accessibles restent généralement en deçà des modèles propriétaires à taille comparable.

3.3 Le système de jugement

Mesurer un taux de réponses correctes suppose de décider automatiquement, pour chaque réponse, si elle est juste. La comparaison littérale au texte attendu a été écartée d'emblée : trop rigide, elle rejetterait une réponse correcte simplement reformulée. Deux méthodes de jugement ont donc été retenues et appliquées en parallèle.

La première vérifie la présence de mots-clés obligatoires, définis question par question. Pour le barème kilométrique, le mot-clé est `0,45`. Ce juge est gratuit, instantané et déterministe, mais grossier. La seconde soumet à un modèle de langage la question, la réponse attendue et la réponse produite, en demandant un verdict binaire ; elle apprécie l'équivalence de sens mais coûte un appel d'API par question.

Leur conservation conjointe se justifie par trois raisons. Leur désaccord signale les cas ambigus : à la question sur le congé pour mariage, l'assistant a répondu « quatre jours ouvrés » alors que le mot-clé attendu était `4` ; le premier juge a conclu à un échec, le second a validé, et le désaccord révélait une défaillance de la métrique, non du système. Le juge par mots-clés sert par ailleurs de recours lorsque l'API est indisponible, situation rencontrée à plusieurs reprises. Enfin, le juge par modèle de langage est lui-même un composant à valider : sa première version appliquait deux règles contradictoires et rejetait à tort les réponses plus complètes que la référence, défaut identifié en le testant sur des cas construits à la main avant de s'en servir.

4. Méthode d'évaluation

4.1 Le jeu de référence

L'évaluation repose sur vingt questions dont les réponses sont connues à l'avance. Chaque entrée comporte quatre champs : la question, la réponse attendue, la liste des mots-clés obligatoires, et le document censé contenir l'information.

Ce dernier champ permet de distinguer deux natures d'échec que le seul taux de réponses correctes confondrait. Si le document attendu n'a pas été remonté, la défaillance est dans la recherche ; s'il l'a été et que la réponse reste fausse, elle est dans la génération. Sans cette distinction, on saurait que le système se trompe sans savoir quel paramètre corriger.

Catégorie	Nombre	Objet
Factuelle	12	Un fait précis dans un seul document
Croisement	3	Information répartie sur deux documents
Piège	3	Deux valeurs voisines aisément confondues
Sans réponse	2	Information absente du corpus

Cette répartition est délibérée. Un jeu composé uniquement de questions faciles afficherait un taux proche de 100 % en permanence et ne détecterait aucune dégradation : une métrique qui ne varie jamais n’informe pas. Les sept questions difficiles créent la marge nécessaire pour que le taux soit sensible à un changement. Les deux questions sans réponse vérifient un comportement qui, pour un assistant d’entreprise, importe autant que l’exactitude : reconnaître son ignorance plutôt qu’inventer une procédure vraisemblable.

4.2 Les métriques

Trois indicateurs sont calculés à chaque exécution. Les **taux de réponses correctes selon chacun des deux juges** mesurent la qualité globale ; leur écart signale les cas où la métrique elle-même est en défaut. Le **taux de rappel de la source** mesure la proportion de questions pour lesquelles le document attendu figure parmi les passages remontés : il évalue la recherche seule, indépendamment de la rédaction.

Un quatrième compteur recense les **erreurs techniques** — API indisponible, quota atteint. Il ne mesure pas le système mais la validité de la mesure : une évaluation comportant des erreurs techniques produit des taux ininterprétables, puisqu’une question non traitée est comptée comme incorrecte.

4.3 Robustesse de l’exécution

Rejouer vingt questions représente quarante appels d’API, dont chacun peut échouer. Chaque question est traitée dans un bloc de capture d’exception : un échec n’interrompt pas la série et la question est marquée en erreur technique. Un mécanisme de réessai avec attente croissante absorbe les dépassements de quota, et une temporisation de huit secondes maintient le débit sous la limite de quinze requêtes par minute, ce qui porte la durée d’une évaluation à environ quatre minutes. La température du modèle est enfin fixée à zéro, tant pour la génération que pour le juge ; la section suivante montre que cette précaution ne suffit pas à rendre les mesures strictement déterministes. —

5. Tests, résultats et cas d’échec

5.1 Protocole et résultats

Six configurations ont été évaluées sur le même jeu de vingt questions, en ne faisant varier qu’un facteur à la fois afin que chaque écart soit attribuable à un paramètre identifié. Chaque exécution a été enregistrée dans MLflow avec ses paramètres et ses métriques.

Taille de fragment	Chevauchement	top_k	Taux correct	Rappel source
500	100	3	90 %	94,4 %
500	100	5	100 %	100 %
300	60	3	80 %	100 %

Taille de fragment	Chevauchement	top_k	Taux correct	Rappel source
800	160	3	70 %	94,4 %
800	160	5	90 %	94,4 %
1200	200	3	70 %	88,9 %




Figure 2: Comparaison des configurations

5.2 Effet des deux paramètres

À taille de fragment constante, augmenter `top_k` de 3 à 5 améliore le résultat dans les deux cas testés : de 90 à 100 % pour des fragments de 500 caractères, de 70 à 90 % pour des fragments de 800. Deux observations concordantes valent mieux qu’un gain isolé. L’interprétation est que le pipeline tolère bien le bruit : transmettre deux passages supplémentaires, parfois hors sujet, ne dégrade pas la réponse, le modèle ignorant ce qui ne sert pas. Le risque de manquer le passage pertinent pèse plus lourd que celui d’en ajouter d’inutiles.

À `top_k` constant, faire varier la taille de fragment de 300 à 1200 caractères donne successivement 80, 90, 70 et 70 % de réponses correctes. Ce résultat contredit l’hypothèse initiale : les premiers échecs observés laissaient penser que des fragments plus longs amélioreraient les choses en préservant les tableaux entiers. La mesure montre l’inverse.

L’explication tient au fonctionnement des embeddings. Un vecteur représente le sens global du texte qu’il encode ; plus le fragment est long, plus il mêle de sujets, et plus son vecteur devient un compromis qui ne ressemble précisément à aucune question. Le taux de rappel le confirme : il tombe à 88,9 % pour les fragments de 1200 caractères, plus mauvaise valeur de la série. La relation entre taille de fragment et qualité n’est donc pas monotone — il existe un optimum intermédiaire, situé ici autour de 500 caractères, qui n’était pas devinable par le raisonnement seul.

5.3 Ce que le rappel de la source révèle

La configuration à 300 caractères présente un profil singulier : 100 % de rappel de la source, mais 80 % de réponses correctes. Le document attendu était donc systématiquement remonté, et la réponse restait pourtant fautive dans une question sur cinq.

L'explication tient à la définition de la métrique. Le rappel est mesuré au niveau du **document**, non du fragment. Avec des fragments courts, l'information se disperse : le bon document est retrouvé, mais le passage remonté n'est pas celui qui contient la réponse. Cette limite méthodologique n'a été identifiée qu'en confrontant les deux métriques.

5.4 Analyse des cas d'échec

Trois échecs observés sur la configuration `top_k = 3` relèvent de trois causes distinctes.

Un échec de la métrique. À la question portant sur le congé pour mariage, l'assistant a répondu « quatre jours ouvrés » alors que le mot-clé attendu était 4. La réponse était exacte ; c'est le juge par mots-clés qui a échoué, faute de reconnaître un chiffre écrit en toutes lettres.

Un échec de recherche. À la question « quand un nouvel arrivant reçoit-il son matériel informatique et par qui ? », les trois passages remontés provenaient tous du document consacré au matériel informatique, dont le vocabulaire correspond littéralement à la question. Le document décrivant le parcours d'intégration, qui contient la réponse, n'a jamais eu de place. L'assistant a déclaré ne pas disposer de l'information — comportement correct au vu du contexte reçu, mais réponse inutile. C'est ce cas que le passage à `top_k = 5` a corrigé.

Un échec de génération. À la question sur le congé pour décès d'un parent, le document attendu figurait parmi les passages remontés, et l'assistant a pourtant répondu ne pas savoir. Le fragment sélectionné contenait une partie du tableau des congés exceptionnels, mais vraisemblablement pas la ligne concernée. Le bon document ne garantit pas le bon passage.

Ces trois cas montrent qu'un taux global ne suffit pas à piloter un système : il indique qu'une dégradation existe, pas où la corriger.

5.5 Variabilité des mesures

Plusieurs exécutions de la configuration retenue, à paramètres strictement identiques, ont produit des taux différents : 100 %, 95 %, 95 %, 90 % et 85 %.

La température était pourtant fixée à zéro. Ce paramètre contrôle le caractère aléatoire de la génération : à chaque étape, le modèle produit une distribution de probabilité sur les mots possibles, et la température détermine comment y puiser. À une valeur élevée, le tirage est aléatoire ; à zéro, le modèle retient systématiquement le mot le plus probable, ce qui devrait rendre la sortie déterministe. Cette attente n'est pas vérifiée en pratique : les modèles servis par API conservent une part de variabilité, liée au traitement par lots côté serveur et à l'ordre des calculs en virgule flottante.

La conséquence est directe. Un écart de dix points entre deux exécutions peut relever du bruit et non d'une dégradation réelle. Le seuil d'alerte a donc été fixé à 90 % plutôt qu'à 95 % : il tolère une question défaillante et ne se déclenche qu'à partir de deux, ce qui limite les fausses alertes.




Figure 3: Suivi de la qualité dans le temps

6. Coût, gouvernance et sécurité

6.1 Coût d'exploitation

Le dispositif d'évaluation est la source de coût dominante, bien avant l'usage courant de l'assistant. Chaque question déclenche deux appels d'API — un pour produire la réponse, un pour la juger — soit quarante appels et quatre minutes par évaluation complète. Rejouée quotidiennement, la surveillance représente environ quatorze mille six cents appels par an.

Ce coût est linéaire en nombre de questions, ce qui installe un arbitrage entre fiabilité de la mesure et dépense : un jeu de cinquante questions autoriserait un seuil plus exigeant, au prix d'un coût multiplié par deux et demi. Deux leviers permettraient de le réduire sans perdre la capacité de détection — supprimer le juge par modèle de langage lors des exécutions de routine, ou découpler les fréquences entre un jeu réduit quotidien et le jeu complet hebdomadaire.

Le calcul des embeddings s'exécute localement et n'entraîne aucun coût d'API. Il mobilise en revanche environ 470 Mo de mémoire vive, ce qui constitue la contrainte matérielle principale du système.

6.2 Gouvernance

Dépendance au fournisseur. Trois modèles successifs ont dû être abandonnés avant d'aboutir à une configuration stable. Cette dépendance impose des mécanismes de repli, mais menace aussi la comparabilité des mesures : si le fournisseur modifie le modèle sous-jacent sans changer son identifiant, une baisse de qualité pourrait être attribuée à tort au corpus. Le modèle utilisé est pour cette raison enregistré comme paramètre de chaque exécution MLflow.

Traçabilité. MLflow conserve les paramètres et métriques de chaque évaluation, Prefect l'historique des exécutions avec leurs journaux, et le workflow n8n est versionné à chaque publication. Le code est suivi sous Git.

Reproductibilité. Les dépendances sont figées dans un fichier `requirements.txt`. Cette reproductibilité reste partielle : l’environnement de développement a imposé un environnement virtuel ouvert aux paquets système, et `n8n` est déployé en conteneur distinct.

Télémetrie. Prefect transmet par défaut des données d’usage anonymes à son éditeur, comportement désactivable par une variable d’environnement. Un composant d’infrastructure qui communique vers l’extérieur sans configuration explicite mérite d’être inventorié.

6.3 Sécurité des données

Le corpus utilisé ici est fictif, ce qui neutralise le risque dans le cadre du projet. Un déploiement réel porterait sur des procédures internes, et l’analyse doit être menée comme si c’était le cas.

Ce qui reste local. L’indexation ne provoque aucune sortie de données : le découpage et le calcul des embeddings s’exécutent sur la machine, et la base vectorielle est un fichier local. L’ensemble du corpus ne transite jamais par un service externe.

Ce qui sort. À chaque question, les passages retrouvés sont transmis à l’API Gemini. Une procédure RH n’est pas une donnée personnelle, mais elle constitue une information interne dont la diffusion échappe à l’entreprise dès lors qu’elle quitte son réseau. Le risque croît si le corpus venait à contenir des éléments nominatifs — organigrammes, situations individuelles, rémunérations. Les conditions de conservation appliquées par le fournisseur devraient alors être examinées, et un modèle hébergé en interne deviendrait le choix par défaut.

Gestion des secrets. La clé d’API est stockée dans un fichier `.env` exclu du dépôt Git, ce qui évite l’erreur la plus courante — la publication d’un identifiant dans un dépôt public. Cette protection reste minimale : le fichier est en clair sur la machine. Un déploiement en production recourrait à un gestionnaire de secrets dédié.

Exposition des services. MLflow, Prefect et `n8n` sont accessibles sans authentification sur l’hôte local. Cette configuration convient à un poste de développement, mais aucun de ces services ne devrait être exposé en l’état sur un réseau d’entreprise. Le webhook `n8n` accepte en particulier toute requête sans vérification d’origine : une authentification par jeton serait nécessaire dès lors qu’il deviendrait joignable au-delà de la machine. La destination des alertes, aujourd’hui un service public de réception de requêtes choisi pour sa simplicité, devrait de même être remplacée par un canal interne.

7. Limites et pistes d’amélioration

7.1 Limites

- **Corpus synthétique.** Plus régulier qu’une documentation réelle : les taux obtenus sont vraisemblablement supérieurs à ceux qu’obtiendrait le même système sur des procédures authentiques.
- **Variabilité des mesures.** Des écarts allant jusqu’à quinze points entre exécutions identiques, malgré une température nulle. Cette variabilité impose un seuil d’alerte permissif et interdit d’interpréter un écart faible comme une dégradation.
- **Reproductibilité de l’environnement.** L’environnement virtuel est ouvert aux paquets du système : plusieurs dépendances sont héritées de l’hôte plutôt qu’installées par `requirements.txt`.

- **Absence d'historique long.** Le dispositif n'a été exécuté que sur quelques jours. Aucune dérive réelle n'a donc été observée : le détecteur est construit, il n'a pas encore eu l'occasion de détecter quoi que ce soit.
- **Réindexation manuelle.** La prise en compte d'une modification du corpus suppose de relancer l'indexation à la main. Tant que cette opération n'est pas effectuée, la base vectorielle conserve l'ancienne version du document et l'assistant répond à partir d'une information périmée — précisément le scénario de dérive silencieuse décrit en introduction. L'indexation est en outre intégrale : la collection est supprimée puis reconstruite en totalité, ce qui reste instantané sur dix documents mais deviendrait coûteux sur un corpus d'entreprise réel.
- **Péremption du jeu de référence.** Les réponses attendues sont figées dans le jeu de questions. Si une procédure est révisée, la réponse attendue devient fausse et la métrique signale une dégradation là où le système a correctement répercuté le changement. L'étalon de mesure vieillit donc au même rythme que le corpus qu'il sert à évaluer, ce qui constitue un coût de maintenance récurrent.
- **Granularité du rappel.** La métrique vérifie qu'un fragment issu du bon document a été remonté, sans garantir qu'il s'agisse du bon fragment.
- **Alerte déclenchée artificiellement.** La chaîne complète a été validée de bout en bout — détection du franchissement par le flux, appel du webhook, évaluation de la condition par n8n, notification transmise. Ce déclenchement a toutefois été provoqué en relevant temporairement le seuil au-dessus de tout résultat atteignable : la qualité mesurée étant restée à 95 % ou plus à chaque exécution, aucune dégradation réelle n'a jamais franchi le seuil de 90 %.
- **Effet secondaire du préfixe de contexte.** Le nom du document préfixant chaque fragment entre dans le calcul de l'embedding : une question comportant le mot « congé » se rapproche mécaniquement de tous les fragments du document sur les congés payés, quel que soit leur contenu. Le bénéfice net de ce choix n'a pas été mesuré.

7.2 Pistes d'amélioration

- **Élargir le jeu de référence.** Cinquante à cent questions réduiraient le poids de chacune dans le total et permettraient un seuil plus exigeant. Le surcoût plaide pour découpler les fréquences.
- **Automatiser la réindexation.** Faire surveiller le dossier du corpus par l'orchestrateur permettrait de déclencher une réindexation dès qu'un document est ajouté ou modifié, suivie immédiatement d'une évaluation. Le flux deviendrait : détection du changement, réindexation, mesure, alerte en cas de dégradation. Cette chaîne traiterait la principale source de dérive identifiée sans intervention humaine. Une indexation incrémentale, ne recalculant que les fragments des documents modifiés, s'imposerait par ailleurs à mesure que le corpus grossit.
- **Rattacher le jeu de référence au corpus.** Associer chaque question au document et à la version dont elle dépend permettrait de signaler automatiquement les questions à réviser lorsque le document source change, plutôt que de découvrir la péremption par une fausse alerte.
- **Mesurer le rappel au niveau du fragment.** Plutôt que d'indiquer le document attendu, le jeu de référence contiendrait une phrase caractéristique devant figurer dans au moins un fragment remonté. La métrique évaluerait alors ce qui compte réellement, et resterait valide lorsque la taille de découpage change.
- **Ajouter un juge de fidélité.** Un troisième juge vérifierait que la réponse est justifiée par les passages transmis, indépendamment de la réponse attendue. Cette métrique détecte les hallucinations, qu'aucun des deux juges actuels ne mesure directement.

- **Recourir à une recherche hybride.** Combiner recherche vectorielle et recherche par mots-clés traiterait le cas d'échec où un document au vocabulaire littéralement proche de la question monopolise les passages remontés.
- **Conteneuriser l'ensemble.** Une orchestration par `docker compose` des quatre composants leverait les réserves sur la reproductibilité et rendrait le déploiement indépendant de la machine hôte.